

C P P

Context Provenance Protocol

От оптимизации затрат к игротейоретической
инфраструктуре обратной связи

Working paper · v0.1 · 2026-05-21
github.com/agisota/cpp-core

Context Provenance Protocol

От оптимизации затрат к игротеоретической инфраструктуре обратной связи

Working paper — версия 0.1 (2026-05-21) Автор: agisota Reference implementation: github.com/agisota/cpp-core (v1.0.0-rc.1) Эта работа — основа для будущей научно-индустриальной публикации; данные с пользовательской машины используются с разрешения.

§

Оглавление

- §I. Проблема: почему агентные системы экономически неэффективны
- §II. Теория: что такое канонизация контекста
- §III. История и prior art: чего раньше не было
- §IV. Реальная валидация: данные с продакшен-машины
- §V. Экономическая модель и unit economics
- §VI. Глубинная гипотеза: feedback loops на хэшах
- §VII. Стабильность хэшей: защита от модельного дрейфа
- §VIII. Архитектура и референс-имплементация
- §IX. Стратегия валидации: эксперименты и метрики
- §X. Roadmap по фазам
- §XI. Go-to-market: пилоты и каналы продаж
- §XII. Инвестиционная стратегия и целевые фонды
- §XIII. Команда, юрилица и инфраструктура
- §XIV. Риски и митигации
- §XV. План действий по неделям
- Приложения: математика, ссылки, расчёты, шаблоны документов

§

§ I

I. Проблема

1.1. Парадокс масштабирования LLM-агентов

В 2024-2026 годах массово появились **многоагентные системы**: Claude Code, Cursor, Cline, Aider, AutoGPT-like harness'ы, RAG-агенты, autonomous research-агенты (Devin, OpenHands, ROX.ONE). Их экономическая природа парадоксальна:

ПАРАДОКС: чем больше агентов, тем хуже unit-экономика

1 агент → стоимость = X
3 агента → стоимость = 3X (без шеринга контекста)
10 агентов → стоимость = 10X (linear scaling)
100 агентов → стоимость = 100X (нет network effect)

Между тем КАЧЕСТВО на агента не растёт линейно. Часто оно снижается (контекст-fragmentation, конфликтующие решения).

В классических распределённых системах с ростом узлов растёт полезный output (Metcalfe, Reed). В агентных системах сегодня – наоборот: с ростом числа агентов растёт стоимость *повторно загружаемого* контекста.

Корень проблемы: каждый агент сегодня загружает контекст как **opaque text blob**. Нет инфраструктурного слоя, позволяющего нескольким агентам *договориться*, что они смотрят на один и тот же контент. Провайдеры (Anthropic, OpenAI) внутри кэшируют префиксы, но **client-side нет видимости**, что попадёт в кэш.

1.2. Конкретный пример (real-world, не выдуманный)

Анализ продакшен-машины пользователя за май 2026:

Метрика	Значение
Общий объём сессий Claude Code	687 MB
Главный проект (craft)	250 MB логов сессий, 16 GB кода
Активных параллельных worktree'ов на одном репозитории	13

Метрика	Значение
Из них с байт-в-байт идентичным AGENTS.md (MD5-confirmed)	9 из 13
Самая длинная сессия	11 MB (≈ 3М токенов контекста)
Длинных сессий в одном проекте за месяц	24
Дублирующих <code>package.json</code> в проекте	8,562
Сессий с multi-agent workflow (ralph/autopilot/swarm)	22

При средней цене Claude API \$3/M input tokens:

```
Грубый расчёт расхода без CPP:
    24 сессий × 200K tokens/сессия × 10 turns × $3/Mt
= 24 × 2M × $3/Mt
= $144/мес ТОЛЬКО на одного разработчика
  ТОЛЬКО на один проект

С учётом swarm (7 параллельных агентов):
    22 swarm-сессий × 7 × 200K × $3/Mt
= $92.4/мес дополнительно

Итого: ~$236/мес × 1 dev × 1 проект = ~$2,832/год

Команда из 5: ~$14K/год
Enterprise из 100: ~$283K/год
SaaS-провайдер с 100K юзеров: $283M/год теоретически
```

И это **с уже работающим prompt caching на стороне Anthropic**. Большая часть этих токенов кэш-миссы — потому что между параллельными агентами и worktree'ами нет синхронизации байтов.

1.3. Регуляторная проблема (вторая половина дилеммы)

С 2025-2026 года включаются регулирующие требования к AI:

- **EU AI Act** (поэтапно 2024-2027): high-risk AI systems обязаны иметь transparency obligations, human oversight, logging, audit trails.
- **GDPR Art. 22**: право на explanation для automated decision-making с «significant effect».
- **NIST AI RMF (USA)**: требует traceability и explainability.
- **PCI DSS / HIPAA / SOX**: domain-specific audit logs.
- **Russian FZ-152**: обработка персональных данных (включает AI-обработку).
- **UAE PDPL (2022)**: Federal Decree-Law No. 45 of 2021 (Personal Data Protection).
- **Saudi PDPL (2023)**: Personal Data Protection Law.

Все эти регуляции **требуют возможности раскрыть** «как AI пришёл к решению X»: на каких данных, версии модели, в какой момент. Сегодня для AI-команд это означает либо **отказ** от применения LLM в regulated workflow, либо **дорогостоящие homegrown audit-системы** (\$1-5M/год на enterprise).

CPP закрывает обе проблемы одним архитектурным решением.

§

§ II

II. Теория

2.1. Что такое канонизация

Канонизация — это процесс приведения данных к **единственному, детерминированному** представлению, при котором семантически эквивалентные данные имеют **бит-в-бит** идентичную сериализацию.

Пример: JSON НЕ канонизирован

```
{"foo": 1, "bar": 2} → байты А  
{"bar": 2, "foo": 1} → байты В  
Семантически одно, но байты разные → разные хэши
```

Пример: DAG-CBOR канонизирован

```
Любой объект {foo: 1, bar: 2} → одни байты  
Любой объект {bar: 2, foo: 1} → ТЕ ЖЕ байты  
    (ключи отсортированы лексикографически)  
    (числа в каноническом представлении)  
    (нет factor-N representations)  
Хэш SHA-256 от этих байт → детерминированный CID
```

DAG-CBOR (RFC 8949 + IPLD-restrictions) — это canonical CBOR с дополнительными ограничениями:

- Только definite-length представления (no streaming markers).
- Integer keys отсортированы.
- Floats только в float64 (без float16/32 variants).
- Нет undefined, simple values только в `true`, `false`, `null`.
- UTF-8 строки в каноническом NFC.

2.2. Content-addressed identification (CID)

CID — это **отпечаток пальца** контента:

```
CID = multihash(SHA-256, DAG-CBOR(canonical(data)))
```

Анатомия:

bafyreif...




Свойства CID:

- **Verifiable:** дано CID + содержимое → можно проверить за 1ms.
- **Collision-resistant:** SHA-256 даёт 2^{128} security level.
- **Self-describing:** в самом CID закодирован codec и hash function.
- **Federable:** CID одинаков везде — на твоей машине, в S3, в IPFS, в чужой системе.

2.3. Семантический граф: Fact, Rule, Calculation, Effect

СРР формализует структуру агентного контекста через четыре типа узлов, заимствованных из W3C PROV-O (provenance ontology) и расширенных:



Узел	Семантика	Подпись	Пример
Fact	Объективное наблюдение	автор (did:key)	ADR от разработчика; tick от Bloomberg; X-ray от медустройства
Rule	Инструкция для обработки	authority (did:key)	«IPC через invoke»; DV01-формула; clinical guideline
CalculationActivity	Применение Rules к Facts	агент (did:key)	code-review-bot прогнал ADR против policy

Узел	Семантика	Подпись	Пример
Effect	Результат с range и confidence	агент-производитель	список затронутых файлов, P&L impact, диагностика

2.4. Трасты-уровни (Trust Tiers)

Не каждое решение требует одинаковой строгости proof'a:

Tier 1 – Content-addressing only

Цена доказательства: \$0
Дает: integrity (контент не подменён)
Кейс: 80% операций – внутренние cache-hits

Tier 2 – N-of-M consensus + TEE

Цена: 3-5× стоимости инференса
Дает: semantic agreement (несколько моделей подтверждают)
+ hardware-trusted execution
Кейс: compliance-reports, mid-stakes решения

Tier 3 – zkML proof

Цена: \$0.5-5/proof, 10-60s latency
Дает: математическое доказательство
Кейс: litigation-grade, SEC filings, regulatory submission

CPP хранит `tier` как поле каждого `CalculationActivity` — приложение выбирает уровень для конкретного workflow.

2.5. Подписи и идентичность (did:key)

Каждый Fact, Rule, Calculation, Effect подписывается ключом автора:

```
SignedEnvelope<T>:  
  payload:    T (FactNode | RuleNode | ...)  
  signer_did: did:key:z6Mk... (Ed25519 public key embedded)  
  signature:  Ed25519(canonical(payload || signed_at))  
  signed_at:  ISO8601
```

`did:key` — это W3C-стандартный self-sovereign identifier:

- Публичный ключ **встроен** в DID (нет нужды в registry).
- Verify за 100µs.
- Cross-platform: работает в браузере, Node.js, Bun, Python, Rust.

Подпись связывает **payload + timestamp** → защита от replay-атак с переправкой старых подписей.

§

§ III

III. История и prior art

3.1. Эволюция подходов к контексту LLM

Эра	Подход	Проблема
2022-2023	Plain prompt text "System prompt + user message"	100% дубликация Нет дедупа
Late 2023	Vector RAG Embeddings → semantic retrieval	Решает другую задачу (selection, не dedup)
Mid 2024	Anthropic prompt caching cache_control breakpoints	Provider-locked Single-session TTL Cache key opaque
Late 2024	Files API OpenAI Files / Anthropic Files	Provider-specific IDs Нет cryptographic guarantee Нет cross-provider sharing
2025	MCP Resources mcp://... URIs	URI-addressed, не content Нет canonical bytes Нет signing
2026 (CPP)	Content-addressed canonical bytes + semantic graph + cryptographic signatures + tier-aware verification	?

3.2. Соседние технологии (то, что мы переиспользуем)

Стандарт	Год	Что взяли	Что НЕ взяли
DAG-CBOR (RFC 8949 + IPLD)	2018	Canonical bytes	(полностью)
CIDv1 (multiformats)	2017	Content addressing	(полностью)
PROV-O (W3C)	2013	Вокабуляр Entity/Activity/Agent	RDF serialization (заменяли на DAG-CBOR)
DID Core (W3C)	2022	did:key для identity	DID-document resolution (отложили)

Стандарт	Год	Что взяли	Что НЕ взяли
MCP Resources (Anthropic)	2024	URI scheme as integration surface	Provider-internal hashing (расширили)
W3C VC (Verifiable Credentials)	2019	Signed claims pattern	JSON-LD overhead (упростили)

3.3. Что НЕ существует до CPP

- **Cross-provider canonical encoding для LLM context.** Anthropic и OpenAI имеют разные внутренние cache hashing. Общего стандарта нет.
- **Семантически-типизированное content-addressing для agentic workflows.** IPFS даёт generic CID для произвольных байтов; PROV-O даёт семантику без content-addressing. CPP — пересечение.
- **Tier-aware verification протокол.** zkML существует, но не интегрирован с content-addressed storage как часть единого протокола.
- **Open standard для signed multi-agent provenance.** Каждый framework (LangChain, AutoGen, CrewAI) делает своё.

3.4. Конкурентный ландшафт

Прямые конкуренты на разные углы:

Конкурент	Что делает	Где не пересекается с CPP
Bittensor / Subnet 23	Verifiable AI inference через restaking	Криптоэкосистема, не drop-in для existing harness
EZKL / Modulus Labs / Giza	zkML proofs	Не content-addressing; не multi-agent provenance
Anthropic prompt caching	Provider-internal cache	Single-provider, не client-controllable
LangChain checkpoints	State persistence	Не content-addressed, не verifiable
W3C Verifiable Credentials	Signed claims	Нет content-addressing; JSON-LD heavy

CPP занимает нишу: protocol-layer abstraction поверх существующих primitive'ов (IPLD + DID + PROV-O + MCP), оптимизированная под LLM agentic workflows.

§ IV

IV. Реальная валидация

4.1. Машинный аудит (данные пользователя)

Anonymized snapshot из реальной dev-машины:

CLAUDE CODE USAGE PATTERN ANALYSIS	
2026-05-21 snapshot	
Storage footprint:	
Session logs total: 687 MB	
└─ Primary project (craft):	250 MB
└─ /tmp ephemeral sessions:	283 MB (478 files)
└─ Other projects (7):	154 MB
Codebase footprint:	
Total primary project: 16.0 GB	
└─ Parallel worktrees of same repo:	13
└─ Identical AGENTS.md files (by MD5):	9 of 13
└─ Duplicate package.json files:	8,562
└─ Duplicate tsconfig.json files:	966
Session patterns:	
Long sessions (>1MB) in primary: 24	
Largest single session: 11 MB (~3M tokens of context)	
Sessions with multi-agent workflow: 22	
└─ ralph-loop:	~10
└─ autopilot:	~6
└─ swarm orchestration:	~6
Estimated wasted tokens (back-of-envelope):	
Same AGENTS.md re-encoded across worktrees per week:	
9 worktrees × 6.2 KB × 8 sessions/week × ~10 turns	
≈ 4.5 MB × 80 = 360 MB redundant context	
≈ 90M tokens "unnecessarily fresh-encoded" per week	
At \$3/M tokens (Claude Sonnet pricing): \$270/week wasted	
Per dev. On one project. ONE.	

4.2. Что это говорит о потенциале

Если экстраполировать с честным дисконтом:

```
Per-developer waste (conservative): $150/мес
Team of 10 devs:                      $1,500/мес = $18K/year
Mid-enterprise 100 devs:              $15,000/мес = $180K/year
Large enterprise 1000 devs:          $150,000/мес = $1.8M/year
SaaS provider 100K active devs: $15M/мес = $180M/year
```

И это **только** на уровне cost-saving. Audit-trail value (compliance) и feedback-loop value (training signal) приходят сверху.

4.3. Идентификация ICP (Ideal Customer Profile)

На основе паттерна выявленного на реальной машине, формируется ICP:

ICP Tier 1 (immediate buyers):

- Engineering teams 50-500 человек
- Используют Claude Code / Cursor / Cline / Aider
- Имеют общий codebase / shared docs / shared workflow
- Несколько параллельных worktree'ов или ветвей
- Видят \$1,000-50,000/мес расходов на LLM API
- Лидер инжиниринга чувствует "почему-то стало дорого"

ICP Tier 2 (regulatory-driven):

- Финтех, медтех, банки, юриспруденция
- Уже используют LLM для compliance-adjacent задач
- Регулятор требует audit trail
- Cost для них – second-order; primary это compliance risk

ICP Tier 3 (frontier multi-agent):

- Autonomous research teams (Anthropic Engineering, Devin, OpenAI Engineering)
- 10+ агентов на одной задаче
- Cost доминирует unit economics
- Уже инвестируют в собственные solutions

[§](#) [V](#)

V. Экономическая модель

5.1. Unit economics клиента

Простая модель savings:

```
Сэкономлено = (Total_input_tokens × Repetition_ratio) × (Cache_hit_discount)
```

Где:

Total_input_tokens = месячный input

Repetition_ratio = % контекста, который повторяется (0.6-0.95)

Cache_hit_discount = 0.9 для Anthropic cached reads (90% off)

Пример для 100-dev enterprise:

Total_input_tokens = 100 devs × 30 sess × 200K × 22 day = 13.2B tokens/мес

Repetition_ratio = 0.7 (типичный shared codebase)

Cache_hit_discount = 0.9

Tokens saved at price = 13.2B × 0.7 × 0.9 = 8.3B tokens/мес

At \$3/M: \$24,900/мес = \$298K/год потенциальная экономия

Realistic capture (50%): \$149K/год

5.2. Pricing модель CPP

Три варианта монетизации, не взаимоисключающих:

Вариант A: SaaS subscription

Free tier: self-hosted, до 10 devs

Team: \$99/dev/мес (10-100 devs)

Enterprise: \$299/dev/мес (>100 devs, SLA, audit features)

Pros: предсказуемый ARR. **Cons:** sales cycle 3-6 мес.

Вариант B: Revenue share

0% pricing; 20% от documented token savings

Pros: Aligned incentives, легко продать. **Cons:** требует измерения и доверия.

Вариант C: Infrastructure subscription

\$5K/мес base + \$0.10/1M tokens passing through CPP

Pros: scales with usage. **Cons:** сложно прогнозировать.

Рекомендуемая модель: B+C hybrid:

- Pilot: 0% pricing на 90 дней.
- Convert: 20% of measured savings, минимум \$2K/мес.
- Self-hosted: \$5K/мес flat для отказывающихся от revenue share.

5.3. Cost structure CPP-провайдера

Затраты на one \$10K MRR enterprise customer:

CPP storage (S3-equivalent):	\$200/мес
Verification compute:	\$300/мес (Tier 1 only)
Audit log retention (7y):	\$150/мес
Customer success (1/4 FTE):	\$2,500/мес
Total COGS:	\$3,150/мес (31.5%)
Gross margin:	68.5%

При scale 100 enterprise customers: \$1M MRR, \$315K COGS, **\$685K gross profit/мес = \$8.2M ARR potential.**

5.4. TAM/SAM/SOM (с уточнениями)

TAM (Total Addressable Market) 2026:

Глобальный объём корп. расходов на LLM API: \$4.8B
Source: Anthropic + OpenAI + Google revenue 2025-2026

SAM (Serviceable Addressable Market):

Корпорации >100 сотрудников, использующие LLM
как часть workflow: \$1.2B

SOM (Serviceable Obtainable Market) 5-year:

С учётом достижимой доли рынка ~15%: \$180M

Realistic 3-year revenue projection:

Год	Customers	ARR/customer	Total ARR
Y1 (2026)	5 pilots	\$50K	\$250K
Y2 (2027)	25 customers	\$80K	\$2M
Y3 (2028)	100 customers	\$120K	\$12M

§

VI. Глубинная гипотеза: feedback loops на хэшах

6.1. Тезис

Cost saving — **поверхностный** value. Реальный приз — формирование training signal для следующих поколений моделей.

ПОВЕРХНОСТНЫЙ СЛОЙ:

\$X/мес savings
Audit-trail для compliance
Multi-agent coordination

ГЛУБИННЫЙ СЛОЙ:

Каноническое представление
всех {fact, event, judgment, decision}
↓
Любая AI-система может:
- подтвердить, что входы те же
- воспроизвести вычисление
- сравнить outcomes объективно
↓
Это позволяет обучать модели
не на raw text, а на
CRYPTO-VERIFIED game tuples:
(context_CID, action_CID, outcome_CID)
↓
Тот, кто владеет каноном —
владеет training data flywheel.

6.2. Аналогии из истории

Технология	Канон	Кто владел
Поиск 2000-х	PageRank graph	Google → монополия
Social graph 2010-х	Friend connections	Facebook → монополия
RLHF 2022-2024	Human preference rankings	Anthropic + OpenAI
AI feedback 2026+	Verified outcome tuples	? (открытая ниша)

6.3. Формальная модель feedback loop

Каждое решение AI-агента — это game tuple:

$$(S_{in}, A, S_{out}, R)$$

где:

S_{in} = state input = CID контекста, который видел агент
 A = action = CID Calculation (model + params + tool_calls)
 S_{out} = state output = CID Effect (что изменилось)
 R = reward = downstream observable (user accepted? bug introduced? cost?)

Сегодня:

- S_{in} фрагментирован по миллионам сессий
- A упаковый (мы не знаем, что именно модель сделала)
- S_{out} сырой текст
- R привязан к user (отдельный feedback channel)

С CPP:

- S_{in} = CID, дедуплицированный, верифицированный
- A = подписанный CalculationActivity с tool_calls
- S_{out} = подписанный EffectNode с range/confidence
- R = подписанный Outcome-Fact от downstream observers

ВСЕ ЧЕТЫРЕ становятся cryptographically linked.

Тренировка следующей модели:

$$L = E[(action_predicted | S_{in}) - A_actual]^2 + E[(outcome_predicted | S_{in}, A) - S_{out_actual}]^2 + reward_shaping(R)$$

Это closed feedback loop на verified data.

6.4. Стратегический момент

В этом моменте есть **5-летнее окно**, пока:

1. Multi-agent системы становятся mainstream (Q3 2026 - 2027).
2. Регуляторное давление на AI audit растёт (EU AI Act полностью в силе 2027).
3. Frontier модели становятся too expensive to train without verified data.
4. Существующие AI labs ещё не зафиксировали канон.

Кто канонизирует первым — становится infrastructure layer на уровне HTTP или TCP/IP. Не visible пользователю, но обязательный.

6.5. Кто платит за канон?

Несколько слоёв willingness-to-pay:

```
Layer 1: Enterprise saving cost (immediate)
    "Save 30-70% on LLM bills"          → $$$

Layer 2: Regulated industries (audit)
    "Verifiable AI for compliance"      → $$$$

Layer 3: AI labs (training signal)
    "Buy our verified feedback corpus"  → $$$$$$
    (e.g., Anthropic pays for verified
     human preferences; tomorrow they
     pay for verified agent outcomes)

Layer 4: Network effect (infrastructure)
    "Everyone uses the canon because
     it's the only way to interop"      → market-making
```

§

§ VII

VII. Стабильность хэшей: защита от модельного дрейфа

7.1. Угроза: hash decay при апгрейде моделей


Когда выходит Claude Opus 5 / GPT-5 / Gemini 3:

- Provider может изменить cache_key hashing.
- Старые canonical bytes могут больше не давать те же cache hits.
- Embedding-based семантические эквивалентности drift.
- Sids для генерации могут не воспроизводиться.

Без защиты — наш протокол распадается каждые 6-12 месяцев.

7.2. Решение: статическая модель-валидатор

Концепция (заимствована из ZK-rollup architecture):



Producer A создаёт Effect.
Шлёт его в Validator Model для канонизации.
Validator выдаёт hash + semantic embedding.
Этот hash детерминирован независимо от того,
какую исходную модель использовал producer.

7.3. Технические компоненты

Компонент	Описание	Зрелость
Frozen validator weights	Один well-defined model checkpoint (например, Llama 3.1 70B при T=0)	Доступен сегодня
Deterministic inference runtime	llama.cpp single-batch CPU mode (битово-воспроизводимый)	Доступен сегодня
Distributed hosting (federation)	HuggingFace Endpoints / TogetherAI / собственная инфра	Доступен
Multi-party SLA	Контрактное обязательство держать checkpoint доступным 5+ лет	Требуется org-уровневой работы
Polarity validation protocol	Не точное совпадение, а semantic polarity (positive/negative zone)	Требуется разработки

7.4. Protocol: Tonality/Polarity Validation

Вместо точного матча байтов — **полярная верификация**:

Producer A заявляет: "Effect X находится в положительной зоне"
(например, "tests pass", "compliance met")

Validator проверяет:

1. Resolve CID X
2. Запустить static model с polarity prompt
3. Получить confidence в polarity claim
4. Подписать verification result

Polarity claims могут быть:

- Binary: positive/negative
- Triple: positive/neutral/negative
- Bounded continuous: [-1.0, 1.0] с CI

ПРЕИМУЩЕСТВО:

- Не требуется точное байтовое совпадение между разными моделями
- "Semantic equivalence" более устойчив к hash decay
- Polarity claims можно делать публично (не PII-leaking)

7.5. ZK-доказательства для polarity claims

Для регулируемых сценариев — zkML proof, что polarity validation прошла:

Claim: "Effect X is in positive zone with confidence ≥ 0.8 "

Proof: zk-SNARK over static-model-inference circuit that:

- Loaded weights_hash = H_model
- Ran inference on input = Effect_CID resolved bytes
- Output polarity score ≥ 0.8

Verifier checks proof in <10ms WITHOUT re-running inference.

Compliance team accepts proof as audit-grade evidence.

zkML practical implementations 2026:

- **EZKL** (<https://github.com/zkonduit/ezkl>) — <100M params, proof time 10-60s
- **Modulus Labs** — commercial offering
- **Giza** — Cairo-based, integration с Starknet
- **Ritual** — early stage

Для статической Llama 3.1 70B сегодня zkML **не работает** напрямую (слишком много параметров).

Realistic path:

1. **Validator distillation**: обучить меньшую модель (~1-10B params) на outputs большой.

2. **zkML на distilled validator.**

3. **Static checkpoint hosting** для polarity ground truth.

§

§ VIII

VIII. Архитектура и референс-имплементация

8.1. Стек слоёв

Layer 9: Industry consortium / standardization	
Layer 8: Polarity Validator Model (static, shared)	← Sprint 6+
Layer 7: MCP Server (JSON-RPC transport + subscriptions)	← Sprint 3+
Layer 6: Storage Federation (S3/IPFS/Filecoin)	← Sprint 2.5+
Layer 5: Resolver + Supersession + Stale-detection	✓ v0.2.0
Layer 4: Storage (Memory + Filesystem)	✓ v0.2.0
Layer 3: Semantic Graph (Fact/Rule/Calc/Effect + Validity)	✓ v0.1.x
Layer 2: Signatures + Identity (did:key + Ed25519)	✓ v0.1.x
Layer 1: CID + DAG-CBOR (canonical encoding)	✓ v0.1.x

8.2. Reference implementation

GitHub: github.com/agisota/cpp-core (public, MIT, v1.0.0-rc.1).

```

cpp-core/
├── src/
│   ├── canonical.ts      # DAG-CBOR encode/decode
│   ├── cid.ts            # CID computation (sync SHA-256)
│   ├── types/            # Fact, Rule, Calculation, Effect, Validity
│   ├── identity/         # did:key, Ed25519 sign/verify
│   ├── storage/          # Storage interface + Memory + Filesystem + Resolver
│   ├── supersession.ts   # Chain follower + stale-fact detection
│   └── mcp/              # URI scheme + Resource shape + pure handlers
├── tests/                # 83 tests, 175 assertions
├── README.md
└── CHANGELOG.md

```

CI: GitHub Actions, runs in 11-14s. All 83 tests pass under TypeScript strict + bun:test.

8.3. Integration surface

Три способа интеграции в существующий harness:

A. Drop-in library (для контролируемых harness'ов)

```
import { FilesystemStorage, computeCID } from "cpp-core";  
  
// В точке загрузки контекста:  
const cid = await storage.put(contextChunk);  
// Передать cid в LLM как ссылку или развернуть в полный prompt
```

B. MCP server (для harness'ов с MCP support)

```
cpp-mcp-server --storage /var/lib/cpp-store  
# Harness подключается через stdio JSON-RPC  
# Запрашивает resources по URI mcp://provenance/<type>/<cid>
```

C. Shadow-traffic mode (для пилотов)

```
cpp-proxy --upstream https://api.anthropic.com \  
          --capture /var/lib/cpp-capture  
# Проксирует requests клиента  
# Параллельно делает canonical encoding и хранит CIDs  
# НЕ влияет на основной поток
```

Вариант **C критичен для пилотов** — позволяет measure без modify.

IX. Стратегия валидации

9.1. Иерархия гипотез

- H0 (null): CPP не даёт измеримой экономии.
- H1 (primary): CPP даёт ≥30% input-token savings на shared-context workflow.
- H2: Anthropic prompt cache hashing совпадает с CPP canonical bytes.
- H3: TTFT на cached prefix снижается ≥50%.
- H4: Multi-agent coordination value выше cost saving в долгосрок.
- H5: Static validator model даёт stable polarity classification independent of upstream model version.
- H6: Feedback loop на verified game tuples производит better fine-tuning.

9.2. План экспериментов (Q3-Q4 2026)

Эксперимент 1: Anthropic cache alignment (Day 1-7)

Гипотеза: Если DAG-CBOR canonical bytes идентичны для двух requests, Anthropic'ий внутренний cache hashing даёт hit.

```

# Pseudocode
import cpp_core
context = build_context(...)
canonical_bytes = cpp_core.encode_canonical(context)

# Request 1
r1 = anthropic.messages.create(
    model="claude-3-5-sonnet",
    system=[{
        "type": "text",
        "text": decode_to_text(canonical_bytes),
        "cache_control": {"type": "ephemeral"}
    }],
    messages=[{"role": "user", "content": "Question 1"}]
)

# Request 2 (5 минут спустя, ТОТ ЖЕ canonical_bytes)
r2 = anthropic.messages.create(...)

# Метрика:
print(r2.usage.cache_read_input_tokens)
# Если > 0 → H2 verified

```

Метрики:

- `cache_read_input_tokens / total_input_tokens` ratio
- TTFT delta
- Cost delta

Sample size: 100 requests, 10 контекстов, 3 модели (sonnet, haiku, opus).

Cost: \$50 для всех тестов.

Time: 1-2 дня от kickoff до publication.

Эксперимент 2: Multi-worktree dedup (Week 2-3)

Setup: деплоить CPP в shadow mode на одну dev-team из 5 человек с 3+ worktree'ами одного проекта.

Метрики:

- Cache hit rate за 14 дней
- \$ saved vs control week
- Developer-reported TTFT subjective improvement
- Number of unique CIDs vs total context loads (dedup ratio)

Success criteria:

- Cache hit rate $\geq 40\%$
- Savings $\geq 25\%$

- Zero workflow disruption reports

Эксперимент 3: Audit-trail replay (Month 2)

Setup: взять 100 архивных AI-решений из прошлого месяца с известными outcomes. Зарегистрировать как Calculations в CPP. Через месяц задать verification query «было ли это решение корректно по правилам v1.0?».

Метрики:

- Replay accuracy
- Reproducibility под смену модели (Sonnet → Haiku → Opus)
- Time to find specific decision

Эксперимент 4: Static validator polarity (Month 3-6)

Setup: обучить distilled polarity validator (1-3B params) на 10K manually-labeled samples. Зафиксировать checkpoint. Запустить через 3 разные modes inference (Claude, GPT, local).

Метрики:

- Inter-rater agreement (κ statistic)
- Stability across model updates
- Cost of validation per claim

9.3. Reverse-validation на исторических данных

Главная техническая хитрость для **первой продажи**:

Клиент даёт нам **read-only** доступ к их LLM usage logs за последние 30 дней. Мы делаем backward analysis:

1. Identify повторяющиеся context patterns (string-level + embedding-level).
2. Compute "as-if CPP" cache hit potential.
3. Quantify \$ saved if CPP было задеплоено в тот период. Этот отчёт — наш pre-sales artifact. Customer видит конкретное число до подписания.

Шаблон отчёта:

CPP RETROACTIVE SAVINGS ANALYSIS	
Customer: [REDACTED]	
Period: 2026-04-01 to 2026-04-30	
Total LLM API spend in period:	\$47,300
Total input tokens:	15.7B
Identified repetition patterns:	
Pattern A (codebase index):	62% of system prompts
Pattern B (AGENTS.md variants):	34% of contexts
Pattern C (Linear snapshots):	21% of contexts
Estimated CPP-with-Anthropic-cache savings:	
Lower bound:	\$11,200 (24%)
Most likely:	\$19,800 (42%)
Upper bound:	\$28,900 (61%)
Annualized projection:	
Lower:	\$134K/year saved
Likely:	\$237K/year saved
Upper:	\$347K/year saved
Pilot recommendation:	
Phase 1 (Month 1):	Shadow deployment, measurement
Phase 2 (Month 2-3):	Production traffic on 1 team
Phase 3 (Month 4+):	Full rollout

Этот отчёт — **главный pre-sales артефакт.**

[§](#) [X](#)

X. Roadmap

10.1. Фаза 0: Foundation (DONE, May 2026)

✓ Reference implementation v1.0.0-rc.1 (github.com/agisota/cpp-core) ✓ Public design document ✓
Reproducible CI

10.2. Фаза 1: Empirical validation (Jun-Aug 2026)

Цели:

- Anthropic cache alignment experiment → publish results
- 3 friendly pilots (own team + 2 design partners)
- Retroactive savings analysis tool

Deliverables:

- arXiv preprint: "Cross-provider canonical encoding for LLM context cache alignment"
- 3 pilot reports with consenting customers
- `cpp-cli analyze` tool для retroactive savings

10.3. Фаза 2: Pre-seed funding + first revenue (Sep-Dec 2026)

Цели:

- Pre-seed round \$500K-\$1M
- 5-10 paying pilots
- Sprint 3 proper (MCP transport)

Deliverables:

- Anthropic Startup Fund application
- OpenAI Fund application
- 5 signed pilot contracts (LOIs)
- Working MCP integration with Claude Code, Cursor

10.4. Фаза 3: Seed + GTM (Q1-Q2 2027)

Цели:

- Seed round \$3-5M
- 20+ enterprise pilots
- Sprint 4 (Polarity validator MVP)

Deliverables:

- Multi-region deployment (US/EU/UAE)
- 3 enterprise customers signed
- Public benchmark suite

10.5. Фаза 4: Scale + Tier 2 (Q3-Q4 2027)

Цели:

- Series A \$15-25M
- 100+ customers, \$5M ARR
- N-of-M consensus + TEE attestation

Deliverables:

- TEE infrastructure deployment
- Industry consortium initiation
- Conference publication (NeurIPS / S&P / USENIX)

10.6. Фаза 5: zkML + Feedback loops (2028+)

Цели:

- Tier 3 (zkML proofs)
- Feedback corpus product (sell verified game tuples to AI labs)
- Industry standard ratification (W3C / IETF)

§ XI

XI. Go-to-market

11.1. Целевые рынки и их специфика

Россия / CIS

Customer profile:

- Sber AI (внутренняя разработка GigaChat, SaluteAI)
- Yandex (YandexGPT, AI-агенты в маркете)
- MTS AI
- Tinkoff (внутренние ML-команды)
- VK (нейросети)
- X5 Group (AI для ритейла)

Caveats:

- Санкции усложняют использование Claude/OpenAI напрямую
- Но: GigaChat, YandexGPT — те же проблемы агентного контекста
- CPP кросс-провайдерский — это плюс

UAE / MENA

Customer profile:

- G42 (Inception AI, Jais model)
- TII (Technology Innovation Institute) — Falcon LLM team
- ADNOC (digital transformation)
- Saudi PIF tech investments
- Aramco Digital
- STC (Saudi Telecom)
- Careem (Uber subsidiary, heavy AI usage)

Caveats:

- Регуляторно проще (UAE PDPL мягче чем GDPR)
- Капитал доступнее
- Sovereign AI initiatives — fit для CPP позиционирования

Казахстан

Customer profile:

- Kaspi.kz (super-app, heavy AI)
- Halyk Bank
- Beeline KZ
- Astana Hub portfolio companies

Caveats:

- Меньший рынок, но: bridge между RU и UAE/MENA
- Astana Hub предоставляет visa/business infrastructure

Mid-East and West

Customer profile:

- Notion, Sourcegraph, Replit (existing Anthropic customers)
- Anthropic itself как enterprise customer for internal use
- Big Four consulting (Deloitte, EY, McKinsey, BCG — все строят AI practices)

11.2. Pilot Playbook

Шаг 1: Pre-sales hook (1 неделя)

Объект: получить read-only доступ к LLM API logs за последний месяц.

Outreach script (адаптированный под русско/MENA):

Subject: Анализ ваших LLM-расходов: 30-70% потенциальной экономии

Здравствуйте, [Name],

Видим, что [Company] активно использует LLM в [public use case].
Мы делаем audit, который выявляет повторяющийся контекст в LLM-сессиях
и quantifies возможную экономию через content-addressed caching.

Анализ занимает 3 дня. Не требует никаких изменений в вашей инфраструктуре.
Если экономия меньше 20% — отчёт бесплатный.
Если больше — пилот по revenue share.

Готовы провести анализ для [Company] на этой неделе?

С уважением,
[Founder]

Шаг 2: Retroactive analysis report (3-5 дней)

См. шаблон выше в §9.3. Customer видит конкретные цифры savings.


Шаг 3: Pilot agreement (1 неделя)

Pilot structure (стандартная):

- **Duration:** 90 дней
- **Pricing:** 0% pricing на pilot period
- **Deployment:** Shadow mode (no production impact)
- **Data access:** Read-only, anonymized, customer-controlled storage
- **Exit conditions:** Customer может остановить anytime
- **Conversion:** Если pilot показывает >\$10K/мес savings → convert на revenue share или Enterprise tier

Шаг 4: Shadow deployment (Day 1-7)

Архитектура deployment:



CPP-проxy **не модифицирует** трафик. Просто:

- Логирует canonical-encoded bytes для каждого request.
- Compute "what cache hit rate WOULD have been" if CPP были инжектированы.
- Хранит в customer's storage.

Установка: один docker run. 30 секунд. Не требует root.

```
docker run -d --name cpp-proxy \  
-p 9999:9999 \  
-v /var/lib/cpp-data:/data \  
-e UPSTREAM=https://api.anthropic.com \  
agisota/cpp-proxy:rc.1
```

*# Customer changes ANTHROPIC_API_URL=http://localhost:9999/api в одном env file.
Всё остальное работает как было.*

Шаг 5: Daily report (через первые 7 дней)

Customer получает каждое утро email-отчёт:

CPP SHADOW REPORT — Day 7

Yesterday:

LLM requests captured:	1,247
Unique canonical contexts:	83
Repetition ratio:	89%

Would-be cache hits:

Total input tokens:	14.2M
Cached (potential):	10.8M (76%)
Fresh (necessary):	3.4M (24%)

Estimated cost saved:	\$35.40
-----------------------	---------

Cumulative (7 days):	\$241.80
Projected monthly:	\$1,036.00

Шаг 6: Conversion conversation (Day 30)

После 30 дней:

- Customer видит accumulated savings (теоретические).
- Предлагаем production deployment.
- Pricing: 20% от documented savings или \$5K/мес minimum.

Шаг 7: Production rollout (Month 2+)

Phased rollout:

- Week 1: 10% traffic через CPP, остальное direct.
- Week 2: 50%.
- Week 4: 100%.
- Continuous monitoring для отката.

11.3. Коммуникационный план: первые 12 недель

Week 1 (Jun 1-7):

Mon: Outreach Sber AI (через LinkedIn + warm intro)
Tue: Outreach Yandex Engineering
Wed: Outreach Anthropic Customer Success
Thu: Outreach G42 (через Hub71 introduction)
Fri: Outreach Tinkoff ML platform team

Week 2 (Jun 8-14):

Mon: First demo call: [whichever responds first]
Wed: Second demo call
Thu: Astana Hub introduction meeting
Fri: Outreach KAUST research group

Week 3 (Jun 15-21):

Tue: Retroactive analysis #1 delivered
Wed: Retroactive analysis #2 delivered
Fri: First pilot contract signed (target)

Week 4 (Jun 22-28):

Mon: Pilot 1 deployment
Wed: Anthropic Startup Fund application submitted
Fri: OpenAI Fund application submitted

Week 5-8 (Jul):

Pilot 1 daily reports
Outreach к VC funds (см. §XII)
Conference paper draft begun

Week 9-12 (Aug):

Pilot 1 conversion conversation
Pilot 2 deployment
arXiv preprint published
Pre-seed term sheet (target)

§ XII

XII. Инвестиционная стратегия

12.1. Капитальная структура

Раунды:

Pre-seed (Q3 2026):	\$500K-\$1M
Valuation cap:	\$5M
Use of funds:	Empirical validation, 2-3 hires
Seed (Q1 2027):	\$3M-\$5M
Valuation:	\$15-25M
Use of funds:	5 enterprise pilots, full team
Series A (Q3 2027):	\$15M-\$25M
Valuation:	\$80-150M
Use of funds:	Geographic expansion, Tier 2/3

12.2. Целевые VC фонды (по фазам)

Pre-seed targets (Q3 2026)

Anthropic Startup Fund (<https://www.anthropic.com/startup-fund>)

- Fit: high (мы DIRECTLY улучшаем Anthropic API economics)
- Check size: \$0.5-3M
- Process: warm intro + technical demo
- **Action:** apply by Aug 2026

OpenAI Startup Fund (<https://openai.fund>)

- Fit: medium (мы кросс-провайдерские, не lock-in to OpenAI)
- Check size: \$1-5M
- **Action:** apply Q4 2026

Sber500 (Russia, Sber's accelerator)

- Fit: high (Russian AI ecosystem)
- Check size: \$100K-1M
- Application: sber500.com
- **Action:** apply Q3 2026

Phystech Ventures (Russia)

- Fit: medium-high (deep tech focus)
- Check size: \$500K-3M
- **Action:** intro через MIPT alumni

Y Combinator (USA, twice yearly)

- Fit: high (infrastructure + AI)
- Check size: \$500K standard
- Application: ycombinator.com
- **Action:** apply for W26 batch (deadline ~Sep 2025 для January 2026 batch)

500 Global MENA (UAE/SA)

- Fit: high (региональный фокус)
- Check size: \$250K-1M
- **Action:** apply через MENA office

Seed targets (Q1 2027)

Andreessen Horowitz (a16z) — крепкая AI infra thesis **Lightspeed Venture Partners** — AI infra focus
Sequoia Capital Index Ventures (London/SF) **G42 Ventures** (UAE) — sovereign AI **Mubadala Capital** (UAE)
Saudi STV / Sanabil (KSA)

Research grants**NSF SBIR Phase I (USA)**

- \$275K, 12 months
- Application windows: Sep 2026, Dec 2026
- Eligibility: US-based legal entity

EU Horizon Europe Cluster 4: Digital, Industry and Space

- Up to €2.5M for cascade-funding
- Open continuously, deadlines quarterly
- Eligibility: EU consortium

UK Innovate UK Smart Grants

- £25K-2M
- Eligibility: UK presence

Russian Science Foundation (РНФ)

- 5-30M RUB (\$60K-360K)
- Open calls 2-3 раза в год
- Eligibility: Russian academic institution

TII Research Grants (UAE)

- Открытые programs для AI safety, infrastructure
- Eligibility: UAE-based, или partnership с ТИ

KAUST Research Grants (Saudi)

- \$50K-\$1M
- Eligibility: academic affiliation, может быть visiting

Astana Hub Tech Garden Grants (Kazakhstan)

- \$20K-100K
- Eligibility: KZ legal entity

12.3. Pitch стратегия

Elevator pitch (30 секунд)

«Мы строим Stripe для агентных систем. Сегодня каждый AI-агент платит за входные токены — даже за абсолютно те же байты, которые сосед уже отправил минуту назад. Мы делаем content-addressed canonical encoding, которое позволяет агентам делиться контекстом byte-for-byte и автоматически срабатывать на provider-side prompt cache. На реальной dev-machine видим 70% redundant tokens. Reference implementation готова. Ищем pre-seed \$500K-\$1M для empirical validation и первых 5 пилотов.»

One-pager (для cold outreach)

См. `/strategy/one-pager.md` (отдельный файл).

Deck structure (для warm meetings)

Slide 1: Cover — CPP logo + tagline
Slide 2: The problem — 1 chart с дублирующими токенами
Slide 3: Why now — multi-agent + regulatory pressure
Slide 4: Solution overview — canonical hashing in 3 steps
Slide 5: Reference implementation — github.com/agisota/cpp-core
Slide 6: Customer pain — real numbers from user's machine
Slide 7: Market — TAM \$4.8B → SOM \$180M
Slide 8: Competitive landscape — где мы НЕ конкурируем
Slide 9: Deep play — feedback loops on hashes (the moonshot)
Slide 10: Business model — revenue share + SaaS tiers
Slide 11: Roadmap — 5 phases
Slide 12: Team — founders + advisors
Slide 13: Ask — \$500K-\$1M pre-seed
Slide 14: Appendix — math, math, math

12.4. Юрисдикции для регистрации

Юрисдикция	Pros	Cons	Costs
Delaware C-Corp (USA)	Standard for VC, easy fundraising	Tax, FATCA reporting	\$400 reg + \$500/yr
Delaware via Stripe Atlas	Turn-key, \$500 incl bank	US-only optimal	\$500 one-time
ADGM (Abu Dhabi)	0% corporate tax (free zone), AI-friendly	Higher setup costs (\$5K)	\$5K + \$3K/yr
DIFC (Dubai)	World-class infrastructure, talent	\$10K+ setup	\$10K + \$5K/yr
AIFC (Astana, Kazakhstan)	English common law, low tax, RU-friendly	Less prestige, smaller market	\$1-3K
Cyprus	EU, low corp tax (12.5%), favorable	Brexit-impacts, paperwork	\$2-5K
Russia (ПФ ООО)	Local market access	Sanctions complications	Low (50K RUB)

Рекомендуемая структура:

HoldCo: Delaware C-Corp (для VC fundraising)
↓
OpCo Russia: ООО (для CIS customers + IP licensing)
OpCo UAE: ADGM или DIFC (для MENA customers + tax efficiency)
R&D arm: Cyprus (для EU customers + tax)

Bootstrap путь:

- Q3 2026:** Stripe Atlas Delaware (\$500). Banking via Mercury.
- Q4 2026:** ADGM SPV (\$5K) для MENA pilots.
- 2027:** Cyprus или другие EU options если EU pilots.

12.5. Visa и легальные перемещения

Для founder, путешествующего между юрисдикциями:

Страна	Visa option	Cost	Time
UAE	Golden Visa (10y), entrepreneur category	~\$3K	30 дней
UAE	Green Visa (5y), freelancer	\$1K	14 дней
Kazakhstan	Astana Hub Tech Visa (5y)	бесплатно	7 дней
Cyprus	Permanent Residence by investment	€300K	6 мес

Страна	Visa option	Cost	Time
Estonia	e-Residency + дист. company	€100	1 мес

Рекомендуемая комбинация:

- Astana Hub Tech Visa (immediate, free, базовая).
- UAE Golden Visa (long-term, prestige).
- Estonia e-Residency (для EU activity).

Сценарий перелёта первой регистрации:

Day 1: Online application Astana Hub (<https://astanahub.com>)
Day 7: Approval, fly to Almaty/Astana
Day 8: Local registration at Astana Hub
Day 10: Bank account at Halyk / Forte
Day 14: KZ-000 registered, ready for first transactions

§ XIII

XIII. Команда, юрлица, инфраструктура

13.1. Core team (Year 1)

Tech Founder/CEO	1.0 FTE	UAE base
- Vision, fundraising, lead architecture		
- Background: AI infrastructure + business		
Research Lead	0.5 FTE	Russia/EU
- Canonical hashing, zkML, polarity validation		
- Background: PhD in CS / cryptography		
Senior Infra Engineer	1.0 FTE	Russia/Kazakhstan
- Bun/TypeScript, distributed systems		
- Background: 5+ years backend		
GTM Lead	1.0 FTE	UAE
- Sales, partnerships, customer success		
- Background: enterprise SaaS sales		
Crypto/Security Engineer	0.5 FTE	EU
- Ed25519, hash security, audit		
- Background: blockchain or security consulting		
Total:	4.0 FTE	
Burn rate:	\$50K-80K/мес (с учётом geographic arbitrage)	

13.2. Advisors (target)

- **Cryptography/zkML expert:** EZKL team, Modulus Labs, или academic
- **AI infrastructure:** Ex-Anthropic / OpenAI engineer
- **Enterprise sales:** Snowflake, Datadog, Confluent veteran
- **Regulatory:** ex-EU AI Act WG member или US AI safety counsel
- **MENA market:** G42 / Mubadala alumni

13.3. Инфраструктура

Development:

Source: GitHub (open core)
CI: GitHub Actions
Package: NPM (cpp-core) + Docker (cpp-mcp-server)

Production:

Hosting: AWS multi-region (US-East, EU-West, ME-South-1 Bahrain)
Storage: S3 + CloudFront для CIDs
Compute: ECS Fargate для validator inference
Database: PostgreSQL (RDS) для metrics

Validator hosting:

Primary: HuggingFace Endpoints для polarity model
Backup: Self-hosted на TII compute (UAE)
Tertiary: Together.ai / Replicate

Monitoring:

Metrics: Grafana Cloud
Logs: Datadog
Errors: Sentry
Status: status.cpp.dev

§ XIV

XIV. Риски и митигации

Риск	Вероятность	Импакт	Митигация
Anthropic меняет cache logic	Medium	High	Спец-update своего канонизатора + diversify к OpenAI/Google cache
Anthropic/OpenAI делает competing protocol	Low-Med	Critical	Open standard позиционирование; speed to market
Hash decay при апгрейде моделей	High	Medium	Polarity validator с frozen weights (§VII)
Pilot не показывает экономию	Medium	High	Retroactive analysis перед pilot — фильтр
Customer concerns о privacy CIDs	Medium	Medium	Encryption layer (H), capability tokens — backlog
Регуляторное давление на open AI canonization	Low	High	EU AI Act compliance работает В НАШУ пользу
Founder bandwidth (single point of failure)	High	Critical	Co-founder hiring приоритет 1
Capital efficiency vs frontier competition	Medium	High	Strict 18-month runway between rounds

§

§ XV

XV. План действий: следующие 12 недель

Week 1 (Jun 1-7, 2026): Validation kickoff

```
Mon: Run Anthropic cache alignment experiment
      Script in /paper/experiments/exp1-cache-alignment.py
      Cost: $50, time: 4 hours

Tue: Publish results (or "no alignment" finding)
      Public gist + tweet thread

Wed-Thu: Build cpp-cli analyze tool
          Reads anonymized API logs, produces retroactive savings report

Fri: Outreach batch #1 (15 companies):
      - Sber AI (через LinkedIn)
      - Yandex Engineering
      - Tinkoff ML platform
      - Cursor
      - Sourcegraph
      - G42 Inception
      - TII Falcon team
      - Anthropic CS
      - Replit
      - Bedrock (AWS)
      - Notion AI
      - Glean
      - Pinecone
      - 10 startups через Y Combinator network
```

Week 2-4 (Jun 8-28): First pilots + Y Combinator app

Week 2:

Mon-Wed: Demo calls (3-5 expected)
Thu: Deliver first retroactive analysis
Fri: Astana Hub Tech Visa application

Week 3:

Mon: First pilot contract signing (target)
Wed: Anthropic Startup Fund application
Fri: Y Combinator W26 application

Week 4:

Mon: Pilot deployment
Wed: Public benchmark suite published
Fri: arXiv preprint draft begun

Week 5-8 (Jul): Validation accumulates

Week 5: Pilot 1 daily reports begin

Week 6: Demo calls #6-10

Week 7: Second pilot contract

Week 8: Pre-seed fundraising kickoff

Week 9-12 (Aug): Pre-seed close

Week 9: Term sheet conversations

Week 10: First pilot 30-day conversion

Week 11: arXiv preprint published

Week 12: Pre-seed close (\$500K-\$1M target)

§ XVI

Заключение

Context Provenance Protocol — это **dual-track play**:

1. **Tactical, immediate**: content-addressed canonical encoding даёт 30-70% экономии на input-токенах для команд с shared context. Reference implementation готова, пилоты можно начинать **на этой неделе**.
2. **Strategic, 5-year**: канонизация фактов и суждений становится infrastructure layer для следующего поколения AI. Тот, кто стандартизирует — владеет training data flywheel.

Текущий артефакт (cpp-core v1.0.0-rc.1) — **технически готовая foundation**. Что нужно дальше:

- **Empirical validation** (4 экспериментов в §IX)
- **First pilots** (3-5 в §XI)
- **Pre-seed funding** (\$500K-\$1M в §XII)

Окно времени: **18 месяцев** до того, как либо Anthropic, либо Bittensor, либо новый игрок займёт canonical layer.

Реальный value сегодня: **dev'y с 13 параллельными worktree'ями ROX.ONE** — это означает \$200-500/мес savings и formal multi-agent coordination. Завтра — рыночная категория с TAM \$4.8B.

Следующее действие: запустить Эксперимент 1 (cache alignment) в понедельник. Стоимость: \$50. Время: 4 часа. Information value: критическая.

§

См. также:

- `00-EXECUTIVE-SUMMARY.md` — короткая версия
- `appendices/01-math.md` — математические выкладки
- `appendices/02-pilots-pipeline.csv` — список target customers
- `appendices/03-fund-targets.csv` — список fund targets
- `strategy/one-pager.md` — investor one-pager
- `strategy/deck-outline.md` — pitch deck structure
- `strategy/pilot-contract-template.md` — template для pilot agreements

COLOPHON

Set in Inter and JetBrains Mono via system-ui stack.

Rendered Markdown → HTML → PDF via marked + Chromium headless.

Source: github.com/agisota/cpp-core

Version: 0.1 · 2026-05-21

Contact: founder@cpp.dev

CPP is an open standard, MIT licensed. This paper is the working draft, version 0.1.